

UNIVERSITÀ DEGLI STUDI DI BRESCIA
DIPARTIMENTO DI INGEGNERIA DELL'INFORMAZIONE

Clustering Pedologico dei Suoli della Capitanata mediante Analisi dei Gradienti Verticali

Progetto per il corso di
Machine Learning e Data Mining (MLDM)
Anno Accademico 2025/2026

Autori:

Mattia Massolari
Matricola: 740458

Marco Mazzardi
Matricola: 741265

Indice

1	Abstract	3
2	Introduzione	3
2.1	Contesto e Motivazione	3
2.2	Obiettivi del Progetto	3
3	Dataset e Ingestione Dati	4
3.1	Fonte dei Dati: SoilGrids	4
3.2	Variabili del Dataset	4
3.3	Pipeline di Ingestione e Integrazione	5
4	Analisi Esplorativa dei Dati (EDA)	6
4.1	Estrazione e Pulizia dello Strato Superficiale	6
4.2	Controlli di Consistenza	6
4.3	Analisi delle Distribuzioni	7
4.4	Matrice di Correlazione	8
5	Feature Engineering: Gradienti Verticali	9
5.1	Motivazione	9
5.2	Gradienti Normalizzati	9
5.3	Selezione delle 13 Feature Finali	10
5.4	Analisi di Correlazione delle Feature Ingegnerizzate	11
6	Metodologia	12
6.1	Standardizzazione dei Dati	12
6.2	Campionamento per Ottimizzazione	12
6.3	Algoritmo 1: K-Means	13
6.3.1	Ricerca del K Ottimale	13
6.3.2	Scelta Finale: K=6	14
6.4	Algoritmo 2: DBSCAN	14
6.5	Algoritmo 3: Bisecting K-Means	15
6.6	Algoritmo 4: Gaussian Mixture Model (EM)	15
6.7	Riduzione Dimensionale: PCA	17
6.8	Metriche di Validazione	17
7	Risultati Sperimentali	18
7.1	Ricerca del K Ottimale	18
7.2	Visualizzazione Avanzata con Yellowbrick	19
7.3	Proiezione PCA dei Cluster	20

7.4	Mappatura Spaziale dei Cluster	21
7.5	Risultati del GMM (Expectation-Maximization)	22
7.5.1	Selezione del Modello: BIC e AIC	22
7.5.2	Mappatura Spaziale GMM	22
7.6	Profilazione dei Cluster	23
7.7	Validazione e Confronto dei Modelli	24
7.7.1	Concordanza tra Algoritmi: ARI e NMI	24
7.8	Efficienza Computazionale: K-Means vs Mini-Batch K-Means	25
8	Discussione e Conclusioni	25
8.1	Sintesi dei Risultati	25
8.2	Limiti dello Studio	26
8.3	Sviluppi Futuri	27

1 Abstract

Il presente lavoro propone un approccio di clustering non supervisionato per la caratterizzazione pedologica dei suoli della regione Capitanata (Puglia, Italia), basato sull'analisi dei **gradienti verticali** delle proprietà chimico-fisiche del suolo.

A partire dai dati geospaziali SoilGrids, sono state ingegnerizzate 13 feature che descrivono le *dinamiche verticali* del profilo pedologico: tassi di variazione normalizzati (gradienti) tra i sei strati di profondità standard (0–200 cm).

Quattro algoritmi di clustering sono stati addestrati e confrontati: ***K*-Means** (con ricerca iperparametri tramite Metodo del Gomito, Silhouette Score, Davies-Bouldin e Calinski-Harabasz), **DBSCAN**, **Bisecting *K*-Means** e **Gaussian Mixture Model (GMM)**, quest'ultimo basato sull'algoritmo Expectation-Maximization (EM) che generalizza il *K*-Means in ambito probabilistico. La validazione è stata condotta mediante Coefficiente di Silhouette, Sum of Squared Error (SSE), Adjusted Rand Index (ARI) e Normalized Mutual Information (NMI). Un confronto di efficienza tra *K*-Means standard e Mini-Batch *K*-Means completa l'analisi.

I risultati mostrano che il *K*-Means con $K=6$ produce la migliore separazione spaziale e agronomica dei cluster, identificando tipologie di suolo con dinamiche verticali distinte e coerenti con la geomorfologia del territorio.

2 Introduzione

2.1 Contesto e Motivazione

La conoscenza dettagliata delle proprietà del suolo riveste un ruolo fondamentale per la gestione agricola sostenibile, la pianificazione territoriale e la modellazione ambientale. In particolare, la *variabilità verticale* del profilo pedologico — ovvero il modo in cui le proprietà chimico-fisiche cambiano scendendo in profondità — fornisce informazioni cruciali sulla genesi del suolo, sulla presenza di orizzonti diagnostici (ad esempio orizzonti argillici o suole di lavorazione) e sul potenziale agronomico di un'area.

La regione della **Capitanata**, situata nella provincia di Foggia, rappresenta una delle principali aree agricole d'Italia, caratterizzata da una notevole variabilità pedologica dovuta alla compresenza di alluvioni recenti, argille plioceniche, depositi calcarei e suoli vulcanici.

2.2 Obiettivi del Progetto

L'obiettivo di questo progetto è applicare tecniche di **apprendimento non supervisionato** (clustering) per:

1. **Identificare tipologie pedologiche omogenee** sulla base delle dinamiche verticali delle proprietà del suolo, senza utilizzare etichette predefinite.
2. **Confrontare algoritmi di clustering** di diversa natura: partizionale (K -Means), basato sulla densità (DBSCAN), gerarchico divisivo (Bisecting K -Means) e probabilistico (Gaussian Mixture Model con algoritmo EM).
3. **Validare la coerenza spaziale** dei risultati, verificando che i cluster individuati nello spazio delle feature assumano una distribuzione geografica coerente con la geomorfologia del territorio.

3 Dataset e Ingestione Dati

3.1 Fonte dei Dati: SoilGrids

I dati utilizzati provengono da **SoilGrids** (<https://soilgrids.org>), un sistema globale di mappatura predittiva del suolo sviluppato dall'ISRIC – World Soil Information. SoilGrids fornisce mappe raster a risoluzione di 250 m per le principali proprietà chimico-fisiche del suolo, distribuite su sei strati di profondità standard: 0–5 cm, 5–15 cm, 15–30 cm, 30–60 cm, 60–100 cm e 100–200 cm.

3.2 Variabili del Dataset

Le variabili estratte per l'area della Capitanata sono riepilogate nella Tabella 1.

Tabella 1: Variabili pedologiche utilizzate nel progetto.

Variabile	Descrizione	Unità
clay	Contenuto di argilla	%
sand	Contenuto di sabbia	%
silt	Contenuto di limo	%
soc	Carbonio organico del suolo	g/kg
bdod	Densità apparente	g/cm ³
cfvo	Frammenti grossolani	%
cec	Capacità di scambio cationico	cmol _c /kg
nitrogen	Azoto totale	g/kg
phh2o	pH in acqua	—
ocd	Densità di carbonio organico	kg/m ³
wv0010	Contenuto idrico a 10 kPa	cm ³ /cm ³
wv0033	Contenuto idrico a 33 kPa (CC)	cm ³ /cm ³
wv1500	Contenuto idrico a 1500 kPa (PA)	cm ³ /cm ³
ocs	Stock di carbonio organico	t/ha
Ksat	Conduttività idraulica saturata (derivata)	cm/giorno

3.3 Pipeline di Ingestione e Integrazione

Il dataset di base è stato fornito in formato NetCDF (.nc), già parzialmente convertito nelle corrette unità di misura fisiche. Per le variabili mancanti nel file NetCDF originale (come `cec`, `phh2o`, `ocd`, `nitrogen` e le variabili idriche), sono stati integrati i file raster in formato GeoTIFF (.tif) per ciascuno dei sei strati di profondità.

L'integrazione è avvenuta tramite le seguenti operazioni:

1. **Caricamento** dei file TIF con `rioxarray` e rimozione della dimensione `band`.
2. **Allineamento spaziale** alla griglia del NetCDF mediante interpolazione nearest-neighbor (`interp_like`).
3. **Scaling condizionato**: per ogni variabile, un controllo sul valore massimo determina se applicare il fattore di conversione previsto dal README di SoilGrids (es. divisione per 10 per il pH, per 100 per l'azoto).

```

1 for var in variabili_tif:
2     da_depths = []
3     for depth in depths:
4         tif_path = os.path.join(base_dir, f"{var}_{depth}_mean.tif")
5         if os.path.exists(tif_path):

```

```

6         da_tif = rioxarray.open_rasterio(tif_path, masked=True)\
7             .squeeze("band").drop_vars("band")
8         da_tif = da_tif.rename({'x': 'lon', 'y': 'lat'})
9         da_matched = da_tif.interp_like(ds_scaled, method="
10             nearest")
11         da_depths.append(da_matched.assign_coords(depth=depth))
12
13     if da_depths:
14         da_3d = xr.concat(da_depths, dim='depth')
15         # Scaling condizionato in base al range osservato
16         if var == 'phh2o' and float(da_3d.max()) > 15:
17             da_3d = da_3d / 10.0
18         elif var == 'nitrogen' and float(da_3d.max()) > 100:
19             da_3d = da_3d / 100.0
20         ds_scaled[var] = da_3d

```

Listing 1: Integrazione dei file TIF con scaling condizionato.

4 Analisi Esplorativa dei Dati (EDA)

4.1 Estrazione e Pulizia dello Strato Superficiale

L'EDA è stata condotta sullo strato superficiale (0–5 cm), selezionando 13 variabili tra fisiche (clay, sand, silt, bdod, soc, cfvo) e chimico-idrologiche (cec, nitrogen, phh2o, ocd, wv0010, wv0033, wv1500).

I dati sono stati sottoposti a una pipeline di pulizia articolata in:

- **Rimozione pixel No-Data e mare:** esclusione dei pixel con valori nulli o zero fittizi per variabili che non possono fisicamente assumere valore zero (pH, densità, frazioni granulometriche).
- **Vincoli fisici:** limiti superiori coerenti con la realtà ($\text{pH} \leq 14$, frazioni $\leq 100\%$, densità $\leq 2.8 \text{ g/cm}^3$).
- **Trimming statistico:** per le variabili prive di limiti fisici noti, rimozione dei valori oltre il 99.9° percentile.

4.2 Controlli di Consistenza

Due verifiche aggiuntive garantiscono la coerenza interna del dataset:

1. **Consistenza granulometrica:** la somma argilla + sabbia + limo deve avvicinarsi al 100%:

$$\text{clay}_{0-5} + \text{sand}_{0-5} + \text{silt}_{0-5} \approx 100\%$$

2. **Consistenza idrologica:** la Capacità di Campo (CC, misurata a 33 kPa) deve essere superiore al Punto di Appassimento Permanente (PA, a 1500 kPa):

$$\theta_{33} > \theta_{1500}$$

Le inversioni anomale sono state conteggiate e segnalate.

4.3 Analisi delle Distribuzioni

Le distribuzioni delle 13 variabili sono state visualizzate mediante istogrammi con sovrapposizione della stima kernel di densità (KDE).




Figura 1: Distribuzioni delle variabili pedologiche nello strato superficiale (0–5 cm). Le curve KDE evidenziano eventuali asimmetrie e multimodalità.

4.4 Matrice di Correlazione

La matrice di correlazione completa (Figura 2) ha evidenziato le relazioni attese tra le variabili:

- Correlazione **positiva forte** tra **soc** e **cec**: la sostanza organica contribuisce significativamente alla capacità di scambio cationico.
- Correlazione **negativa** tra **clay** e **sand**: la complementarietà granulometrica.

- Correlazione **positiva** tra le variabili idriche (wv0010, wv0033, wv1500): coerenza della ritenzione idrica.




Figura 2: Matrice di correlazione delle variabili pedologiche superficiali. I valori numerici sono annotati nella heatmap `coolwarm`.

5 Feature Engineering: Gradienti Verticali

5.1 Motivazione

Un clustering basato sulle sole variabili superficiali cattura solo un'istantanea bidimensionale del suolo. Per cogliere la complessità del profilo pedologico, è necessario descrivere *come* le proprietà cambiano con la profondità. A tal fine, sono stati calcolati i **gradienti normalizzati** tra strati consecutivi.

5.2 Gradienti Normalizzati

Il **gradiente normalizzato** quantifica il tasso di variazione tra due strati consecutivi, normalizzato per la distanza (in cm) tra i centri degli strati:

$$g_{i \rightarrow i+1}^{(v)} = \frac{X_{d_{i+1}}^{(v)} - X_{d_i}^{(v)}}{z_{i+1} - z_i} \quad (1)$$

dove z_i e z_{i+1} sono i punti medi (in cm) dei due strati. I punti medi utilizzati sono: 2.5, 10.0, 22.5, 45.0, 80.0 e 150.0 cm (Tabella 2).

Tabella 2: Punti medi degli strati di profondità SoilGrids.

Strato	Punto medio (cm)
0–5 cm	2.5
5–15 cm	10.0
15–30 cm	22.5
30–60 cm	45.0
60–100 cm	80.0
100–200 cm	150.0

Questa normalizzazione è fondamentale perché gli strati SoilGrids hanno spessori diversi (5, 10, 15, 30, 40 e 100 cm): senza normalizzazione, il gradiente tra 60–100 cm e 100–200 cm (distanza di 70 cm tra i centri) non sarebbe comparabile con quello tra 0–5 cm e 5–15 cm (distanza di 7.5 cm).

```

1 layer_midpoints = {
2     '0-5cm': 2.5, '5-15cm': 10.0, '15-30cm': 22.5,
3     '30-60cm': 45.0, '60-100cm': 80.0, '100-200cm': 150.0
4 }
5
6 def calc_gradient(da, l_top, l_bottom):
7     dz = layer_midpoints[l_bottom] - layer_midpoints[l_top]
8     return (da.sel(depth=l_bottom) - da.sel(depth=l_top)) / dz

```

Listing 2: Calcolo dei gradienti normalizzati tra strati consecutivi.

5.3 Selezione delle 13 Feature Finali

Dopo il calcolo, sono state selezionate 13 feature suddivise in sei gruppi tematici (Tabella 3). Ogni gradiente è stato scelto per catturare una specifica dinamica pedologica lungo il profilo verticale. Oltre alle variabili pedologiche classiche, è stata inclusa la **conduttività idraulica saturata** (Ksat), già presente nel dataset NetCDF in quanto derivata mediante funzioni di pedotrasferimento a partire dalle variabili tessiturali e idrologiche.

Tabella 3: Le 13 feature selezionate per il clustering, raggruppate per tipologia pedologica.

Gruppo	Feature	Interpretazione
Argilla	clay_grad_0-5_to_5-15	Dinamica tessiturale superficiale
	clay_grad_5-15_to_15-30	Inizio lisciviazione argilla
	clay_grad_15-30_to_30-60	Orizzonte argillico (Bt)
Sabbia	sand_grad_30-60_to_60-100	Discontinuità sedimentarie
SOScheletro	cfvo_grad_15-30_to_30-60	Transizioni litologiche
	cfvo_grad_60-100_to_100-200	Contatto con roccia madre
SOC	soc_grad_0-5_to_5-15	Crollo iniziale sost. organica
	soc_grad_5-15_to_15-30	Esaurimento zona radicale
BDOD	bdod_grad_5-15_to_15-30	Suola di aratura
	bdod_grad_15-30_to_30-60	Compattazione profonda
	bdod_grad_30-60_to_60-100	Transizione substrato
Ksat	Ksat_grad_0-5_to_5-15	Variazione drenaggio superficiale
	Ksat_grad_15-30_to_30-60	Variazione drenaggio profondo

5.4 Analisi di Correlazione delle Feature Ingegnerizzate

Le correlazioni tra le 13 feature ingegnerizzate sono state analizzate mediante la matrice di correlazione di Pearson (Figura 3). Un controllo automatico ha verificato l'assenza di coppie con collinearità critica ($|r| > 0.8$), confermando che lo spazio delle feature è ben bilanciato e non richiede ulteriore riduzione dimensionale.

Le correlazioni osservate confermano le attese pedologiche:

- Correlazione **negativa** tra i gradienti di SOC e i gradienti di BDOD: dove la sostanza organica cala rapidamente, la densità apparente aumenta.
- Correlazione **negativa** tra i gradienti di argilla e il gradiente di sabbia: la complementarietà tessiturale è preservata anche nelle dinamiche verticali.
- I gradienti di Ksat riflettono indirettamente le dinamiche tessiturali, con correlazioni coerenti rispetto ai gradienti di argilla e BDOD.




Figura 3: Matrice di correlazione (triangolo inferiore) dei 13 gradienti verticali normalizzati. Nessuna coppia supera la soglia critica $|r| > 0.8$.

6 Metodologia

6.1 Standardizzazione dei Dati

Le 13 feature selezionate presentano scale e deviazioni standard molto diverse. Per evitare che le variabili a scala maggiore dominino il calcolo delle distanze euclidee, è stato applicato uno **StandardScaler**:

$$\tilde{x}_j = \frac{x_j - \mu_j}{\sigma_j} \quad (2)$$

dove μ_j e σ_j sono rispettivamente la media e la deviazione standard della j -esima feature sul dataset completo.

6.2 Campionamento per Ottimizzazione

Per rendere computazionalmente fattibile la ricerca degli iperparametri (in particolare il calcolo del Coefficiente di Silhouette, che ha complessità $O(n^2)$), è stato estratto un campione casuale di **15 000 pixel** dal dataset standardizzato.

6.3 Algoritmo 1: K-Means

L'algoritmo *K*-Means partiziona n osservazioni in K cluster minimizzando la **Sum of Squared Errors** (SSE) intra-cluster:

$$\text{SSE} = \sum_{k=1}^K \sum_{\mathbf{x}_i \in C_k} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2 \quad (3)$$

dove $\boldsymbol{\mu}_k$ è il centroide del cluster C_k . L'inizializzazione dei centroidi è stata effettuata con la strategia **k-means++**, che seleziona i centri iniziali in modo da massimizzare la distanza reciproca, garantendo una convergenza più rapida e stabile.

6.3.1 Ricerca del K Ottimale

La determinazione del numero ottimale di cluster è stata affrontata con quattro metriche complementari, calcolate per $K \in [2, 12]$:

1. **Metodo del Gomito (Inerzia)**: la curva di inerzia (SSE) al variare di K viene analizzata con l'algoritmo **KneeLocator** della libreria **kneed**, che individua automaticamente il punto di flesso geometrico ("gomito") nella curva convessa decrescente.
2. **Coefficiente di Silhouette**: misura la coesione intra-cluster e la separazione inter-cluster (cfr. Sezione 6.8). Il K con il valore massimo è selezionato.
3. **Indice di Davies-Bouldin (DB)**: valuta la somiglianza tra cluster adiacenti. Definito come:

$$\text{DB} = \frac{1}{K} \sum_{k=1}^K \max_{j \neq k} \left(\frac{s_k + s_j}{d_{kj}} \right) \quad (4)$$

dove s_k è la dispersione media del cluster k e d_{kj} la distanza tra i centroidi k e j . Un valore **più basso** indica cluster meglio separati.

4. **Indice di Calinski-Harabasz (CH)**: rapporto tra la dispersione inter-cluster e intra-cluster, pesato per i gradi di libertà:

$$\text{CH} = \frac{\text{SSB}/(K-1)}{\text{SSW}/(n-K)} \quad (5)$$

dove SSB è la varianza inter-cluster e SSW la varianza intra-cluster. Un valore **più alto** indica cluster più compatti e separati.

```

1 k_values = list(range(2, 13))
2 for k in k_values:
3     model = KMeans(n_clusters=k, init="k-means++",
4                     n_init=10, max_iter=300, random_state=42)
5     labels = model.fit_predict(X_search)
```

```

6
7     inertia_values.append(model.inertia_)
8     silhouette_scores.append(silhouette_score(X_search, labels))
9     db_scores.append(davies_bouldin_score(X_search, labels))
10    ch_scores.append(calinski_harabasz_score(X_search, labels))
11
12    # Individuazione automatica del gomito
13    kneedle = KneeLocator(k_values, inertia_values,
14                          curve="convex", direction="decreasing",
15                          interp_method="polynomial")
16    best_k_elbow = kneedle.elbow

```

Listing 3: Calcolo delle quattro metriche per la ricerca del K ottimale.

6.3.2 Scelta Finale: K=6

I risultati delle quattro metriche (Tabella 4) sono stati analizzati congiuntamente. Sebbene metriche come la Silhouette e il Davies-Bouldin tendano a favorire valori bassi di K (ad esempio $K = 2$), producendo una separazione binaria del territorio priva di sfumature agronomiche, il Metodo del Gomito ha indicato un punto di flesso coerente con $K = 6$.

La scelta finale di $K=6$ è stata guidata da un bilanciamento tra i criteri statistici e le considerazioni pedologiche di dominio: con sei cluster è possibile distinguere tipologie di suolo con dinamiche verticali distinte (ad esempio, suoli con forte lisciviazione argillosa vs. suoli con profilo uniforme, suoli con suola di lavorazione vs. suoli profondi organici).

6.4 Algoritmo 2: DBSCAN

Il **DBSCAN** (Density-Based Spatial Clustering of Applications with Noise) identifica cluster come regioni ad alta densità separate da regioni a bassa densità, classificando come *rumore* (-1) i punti isolati.

Due sono i parametri chiave:

- ε (**eps**): raggio massimo del vicinato.
- **min_samples**: numero minimo di punti per formare un nucleo denso.

Il parametro **min_samples** è stato fissato a 26 ($\approx 2 \times d$, con $d = 13$ il numero di feature), seguendo le linee guida per dati ad alta dimensionalità. La determinazione di ε è stata effettuata tramite il **grafico K-NN distance**: calcolando la distanza dal k -esimo vicino più prossimo (con $k = 26$) e ordinando i valori in modo crescente, si individua il punto di ginocchio che segna il passaggio da “densità intra-cluster” a “distanza inter-cluster”. Il valore scelto è stato $\varepsilon = 1.9$.




Figura 4: Grafico delle distanze K-NN per la determinazione dell'epsilon ottimale del DBSCAN. Il punto di ginocchio è stato individuato nella regione $\varepsilon \approx 1.9$.

6.5 Algoritmo 3: Bisecting K-Means

Il **Bisecting K-Means** è un approccio gerarchico *divisivo* (top-down): parte da un unico macro-cluster e lo suddivide iterativamente in due sotto-cluster fino a raggiungere il numero desiderato di partizioni.

A ogni iterazione, il cluster con la varianza interna maggiore viene selezionato e bipartito con un K-Means a $K = 2$. Il processo è stato configurato con $K = 6$ per garantire un confronto equo con il K-Means standard.

Per rendere il confronto visivo immediato, le etichette dei cluster generati dal Bisecting K-Means sono state **allineate** a quelle del K-Means standard mediante l'algoritmo ungherese (`linear_sum_assignment` sulla matrice di confusione), minimizzando la discrepanza complessiva tra le due partizioni.

6.6 Algoritmo 4: Gaussian Mixture Model (EM)

Il **Gaussian Mixture Model** (GMM) generalizza il K-Means in ambito probabilistico, modellando i dati come una miscela di K distribuzioni gaussiane multivariate:

$$p(\mathbf{x}) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x} \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \quad (6)$$

dove π_k sono i pesi di miscelazione ($\sum_k \pi_k = 1$), $\boldsymbol{\mu}_k$ e $\boldsymbol{\Sigma}_k$ sono la media e la matrice di covarianza della k -esima componente gaussiana.

I parametri vengono stimati mediante l'algoritmo iterativo **Expectation-Maximization** (EM):

1. **E-step (Expectation)**: per ogni campione $\mathbf{x}_i$, si calcola la *responsabilità* γ_{ik} , ovvero la probabilità a posteriori che $\mathbf{x}_i$ appartenga alla componente k :

$$\gamma_{ik} = \frac{\pi_k \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)} \quad (7)$$

2. **M-step (Maximization)**: si aggiornano i parametri di ogni componente usando le responsabilità come pesi:

$$\boldsymbol{\mu}_k^{\text{new}} = \frac{\sum_i \gamma_{ik} \mathbf{x}_i}{\sum_i \gamma_{ik}} \quad (8)$$

$$\boldsymbol{\Sigma}_k^{\text{new}} = \frac{\sum_i \gamma_{ik} (\mathbf{x}_i - \boldsymbol{\mu}_k^{\text{new}})(\mathbf{x}_i - \boldsymbol{\mu}_k^{\text{new}})^\top}{\sum_i \gamma_{ik}} \quad (9)$$

$$\pi_k^{\text{new}} = \frac{1}{n} \sum_i \gamma_{ik} \quad (10)$$

L'iterazione prosegue fino a convergenza della log-verosimiglianza. Rispetto al K -Means, il GMM offre due vantaggi fondamentali:

- **Assegnazione probabilistica** (*soft clustering*): ogni pixel riceve una probabilità di appartenenza a ciascun cluster, piuttosto che un'assegnazione deterministica. Questo è particolarmente utile in pedologia, dove le transizioni tra tipi di suolo sono graduali.
- **Cluster ellissoidali**: la matrice di covarianza completa consente di modellare cluster non sferici, catturando correlazioni tra le feature.

Per la selezione del numero ottimale di componenti, sono stati utilizzati il **Bayesian Information Criterion (BIC)** e l'**Akaike Information Criterion (AIC)**:

$$\text{BIC} = -2 \ln \hat{L} + p \ln n \quad (11)$$

$$\text{AIC} = -2 \ln \hat{L} + 2p \quad (12)$$

dove $\hat{L}$ è la verosimiglianza massimizzata, p il numero di parametri liberi e n la dimensione del campione. Entrambi i criteri penalizzano la complessità del modello, ma il BIC impone una penalità più severa, tendendo a preferire modelli più parsimoniosi.

Il modello finale è stato configurato con `covariance_type='full'` (matrice di covarianza completa per ogni componente) e $K = 6$ per consentire un confronto equo con gli altri algoritmi.

6.7 Riduzione Dimensionale: PCA

Per la **visualizzazione** dei cluster nello spazio delle feature (13 dimensioni), è stata applicata un'analisi delle Componenti Principali (PCA) per proiettare i dati in 2D:

$$\mathbf{z}_i = \mathbf{W}^\top \tilde{\mathbf{x}}_i \quad (13)$$

dove $\mathbf{W} \in \mathbb{R}^{13 \times 2}$ è la matrice delle prime due componenti principali, calcolate come gli autovettori associati ai due autovalori maggiori della matrice di covarianza.

6.8 Metriche di Validazione

La validazione dei modelli è stata condotta con metriche sia interne (non richiedono etichette ground-truth) che relative (confronto tra partizioni).

Coefficiente di Silhouette. Per ogni campione i :

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \quad (14)$$

dove $a(i)$ è la distanza media intra-cluster e $b(i)$ è la distanza media al cluster più vicino. Il valore medio $\bar{s} \in [-1, 1]$: valori prossimi a 1 indicano cluster ben separati.

Nota metodologica: per il DBSCAN, il Coefficiente di Silhouette è stato calcolato *escludendo* i punti classificati come rumore (etichetta -1). Includere tali punti penalizzerebbe artificialmente l'algoritmo, poiché i punti di rumore non appartengono ad alcun cluster e generano valori di silhouette fortemente negativi, distorcendo la media complessiva.

Sum of Squared Error (SSE / Inerzia). Definita nell'Eq. (3), misura la coesione interna dei cluster. Un valore più basso indica cluster più compatti. Questa metrica non è applicabile al DBSCAN né al GMM (che ottimizza la verosimiglianza anziché l'SSE).

BIC e AIC. Per il GMM, la selezione del modello è stata guidata dal BIC e dall'AIC (cfr. Sezione 6.6), che bilanciano bontà del fit e complessità.

Adjusted Rand Index (ARI). Misura la concordanza tra due partizioni, corretta per il caso. Assume valori in $[-1, 1]$: un ARI di 1 indica accordo perfetto, 0 indica concordanza casuale.

Normalized Mutual Information (NMI). Quantifica l'informazione condivisa tra due partizioni, normalizzata nell'intervallo $[0, 1]$. Valori elevati indicano forte accordo strutturale.

7 Risultati Sperimentali

7.1 Ricerca del K Ottimale

I risultati delle quattro metriche di validazione interna sono sintetizzati nella Tabella 4 e visualizzati nella Figura 5.

Tabella 4: Riepilogo dei valori di K suggeriti dai quattro metodi.

Metodo / Metrica	Criterio	K suggerito
Metodo del Gomito (KneeLocator)	Punto di flesso	6
Silhouette Score	Massimo	2
Davies-Bouldin	Minimo	11
Calinski-Harabasz	Massimo	2
K finale (dominio)	Agronomico	6

Il Metodo del Gomito conferma $K = 6$ come punto di flesso; le metriche Silhouette e CH favoriscono $K = 2$ (separazione binaria), mentre il DB suggerisce $K = 11$ (frammentazione eccessiva).




Figura 5: Le quattro metriche per la selezione del K ottimale: Curva del Gomito (Inerzia), Coefficiente di Silhouette, Indice di Davies-Bouldin e Indice di Calinski-Harabasz. La linea tratteggiata rossa indica $K = 6$.

7.2 Visualizzazione Avanzata con Yellowbrick

La libreria Yellowbrick ha fornito tre visualizzazioni diagnostiche complementari che confermano la validità della partizione scelta:

1. **KElbowVisualizer**: individuazione automatica del punto di gomito con indicatore visivo.
2. **SilhouetteVisualizer**: profilo di silhouette per $K = 6$, che mostra la densità e l'eventuale sbilanciamento dei cluster. Ogni “lama” del grafico rappresenta un cluster: la larghezza indica la dimensione, l'estensione orizzontale la coesione interna.
3. **InterclusterDistance**: proiezione 2D dei centroidi con cerchi proporzionali alla dimensione dei cluster, per valutare la sovrapposizione spaziale.




Figura 6: Profilo Silhouette per $K = 6$ (Yellowbrick). Ogni “lama” rappresenta un cluster: la coesione interna è indicata dall’ampiezza orizzontale, la linea tratteggiata verticale segna la media globale.




Figura 7: Mappa delle distanze inter-cluster (Yellowbrick). I centroidi sono proiettati in 2D; la dimensione dei cerchi è proporzionale al numero di pixel assegnati a ciascun cluster.

7.3 Proiezione PCA dei Cluster

La Figura 8 mostra la proiezione dei cluster nello spazio delle prime due componenti principali. La separazione visiva dei cluster conferma che le feature ingegnerizzate catturano strutture significative nei dati, anche se la sovrapposizione parziale è attesa dato che la PCA a due componenti comprime 13 dimensioni.




Figura 8: Proiezione PCA 2D dei cluster K -Means con $K = 6$. Le percentuali sugli assi indicano la varianza spiegata da ciascuna componente principale.

7.4 Mappatura Spaziale dei Cluster

Nonostante l'algoritmo non abbia ricevuto informazioni spaziali (coordinate geografiche), i cluster assumono una distribuzione geografica coerente con la geomorfologia della Capitanata (Figure 9–10).




Figura 9: Mappatura spaziale dei cluster K -Means con $K=6$ sulla regione Capitanata. La coerenza geografica dei cluster conferma la validità pedologica dell'analisi.




Figura 10: Confronto delle mappature spaziali per DBSCAN e Bisecting K -Means.

7.5 Risultati del GMM (Expectation-Maximization)

7.5.1 Selezione del Modello: BIC e AIC

La Figura 11 mostra l'andamento di BIC e AIC al variare del numero di componenti gaussiane ($K \in [2, 12]$). Entrambi i criteri decrescono all'aumentare di K , con un rallentamento della discesa intorno a $K = 6$, confermando la ragionevolezza della scelta del modello a 6 componenti.




Figura 11: Curve BIC e AIC per il GMM al variare del numero di componenti. La linea tratteggiata rossa indica $K = 6$.

7.5.2 Mappatura Spaziale GMM

La Figura 12 mostra la mappatura dei cluster GMM. Rispetto al K -Means, il GMM tende a produrre confini inter-cluster più sfumati, coerentemente con la natura probabilistica dell'assegnazione. L'analisi dell'incertezza ha evidenziato la percentuale di pixel con probabilità di assegnazione inferiore al 70%, corrispondenti alle zone di transizione pedologica.




Figura 12: Mappatura spaziale dei cluster GMM con $K=6$. L’assegnazione è basata sulla componente gaussiana con probabilità a posteriori massima (*hard assignment*). Le etichette sono allineate al K -Means per confronto diretto.

7.6 Profilazione dei Cluster

La heatmap dei centroidi standardizzati (Z-score) permette di interpretare il “profilo agronomico” di ciascun cluster (Figura 13). Valori fortemente positivi (rossi) indicano che il gradiente di una determinata variabile è nettamente superiore alla media regionale; valori negativi (blu) indicano il comportamento opposto. Questa rappresentazione consente di associare a ciascun cluster una descrizione pedologica qualitativa.




Figura 13: Profilo agronomico dei 6 cluster basato sugli Z-score dei centroidi. Valori positivi (rossi) indicano gradienti superiori alla media regionale; valori negativi (blu) indicano gradienti inferiori.

7.7 Validazione e Confronto dei Modelli

La Tabella 5 riporta il confronto quantitativo tra i quattro algoritmi. Si noti che per il DBSCAN il Coefficiente di Silhouette è stato calcolato escludendo i punti di rumore (cfr. Sezione 6).

Tabella 5: Confronto delle metriche di validazione interna ($N = 89\,786$ pixel validi).

Algoritmo	Silhouette ($\uparrow$)	SSE / Inerzia ($\downarrow$)
K-Means ($K = 6$)	0.1041	762 167
Bisecting K-Means ($K = 6$)	0.0739	793 841
DBSCAN ($\varepsilon = 1.9$)	0.0869*	N/A
GMM / EM ($K = 6$)	0.0658	N/A [†]

*Calcolato escludendo i 5 570 pixel (6.20%) classificati come rumore (-1).

[†]Il GMM ottimizza la log-verosimiglianza ($BIC = 2\,781\,079$, $AIC = 2\,775\,163$), non l'SSE.

7.7.1 Concordanza tra Algoritmi: ARI e NMI

Per quantificare la concordanza strutturale tra le partizioni prodotte dai diversi algoritmi, sono stati calcolati l'Adjusted Rand Index (ARI) e la Normalized Mutual Information (NMI) (Tabella 6).

Tabella 6: Concordanza tra le partizioni dei diversi algoritmi.

Confronto	ARI	NMI
K-Means vs Bisecting K-Means	0.458	–
K-Means vs GMM (EM)	0.387	0.462

ARI = 1 indica accordo perfetto; NMI = 1 indica massima informazione condivisa.

Un ARI di 0.458 tra *K*-Means e Bisecting *K*-Means indica una concordanza moderata tra le due strategie di partizionamento: le partizioni condividono buona parte della struttura, ma l’approccio divisivo top-down produce differenze nella gerarchia di suddivisione. La concordanza con il GMM (ARI = 0.387, NMI = 0.462) conferma che l’assegnazione probabilistica è coerente con quella deterministica, pur con differenze significative nelle zone di transizione pedologica (15.3% dei pixel con probabilità < 70%).

7.8 Efficienza Computazionale: K-Means vs Mini-Batch K-Means

Per valutare la scalabilità dell’approccio su dataset geospaziali di grandi dimensioni, è stato condotto un confronto tra *K*-Means standard e **Mini-Batch K-Means** (Tabella 7).

Il Mini-Batch *K*-Means elabora i dati a blocchi di dimensione fissa (`batch_size` = 1024), aggiornando i centroidi in modo incrementale. Questo approccio riduce drasticamente il tempo di addestramento con un trade-off minimo in termini di inerzia.

Tabella 7: Confronto efficienza su 89 786 pixel della Capitanata.

Algoritmo	Tempo (s) (↓)	Inerzia (↓)
K-Means Standard	0.437	762 167
Mini-Batch K-Means	0.141	780 138

Il Mini-Batch *K*-Means ha dimostrato un’accelerazione di circa $3\times$ rispetto al *K*-Means standard, con un incremento dell’inerzia di circa il 2.4% (da 762 167 a 780 138), confermando la sua idoneità per applicazioni geospaziali su larga scala.

8 Discussione e Conclusioni

8.1 Sintesi dei Risultati

Il lavoro ha dimostrato che l’approccio basato sui **gradienti verticali** consente di superare i limiti del clustering bidimensionale, catturando informazioni sulla struttura tridimensionale del profilo pedologico. I principali risultati sono:

1. La **feature engineering** basata su 13 gradienti normalizzati si è dimostrata efficace nel catturare le dinamiche verticali del suolo, producendo cluster con interpretazione agronomica chiara. L'analisi di correlazione ha confermato l'assenza di collinearità critica tra le feature.
2. Il **K-Means** con $K=6$ ha prodotto la migliore separazione spaziale, con cluster geograficamente coerenti con la geomorfologia della Capitanata. La scelta di K è stata supportata dal Metodo del Gomito, dall'Indice di Davies-Bouldin e da considerazioni agronomiche di dominio.
3. Il **DBSCAN** ha classificato una porzione significativa di pixel come rumore, confermando che la distribuzione dei dati nello spazio dei gradienti non è caratterizzata da cluster a densità nettamente diversa, ma piuttosto da regioni a densità omogenea (scenario favorevole al K -Means).
4. Il **Bisecting K-Means** ha fornito risultati con concordanza moderata rispetto al K -Means standard ($ARI = 0.458$), indicando che l'approccio divisivo top-down converge verso una struttura simile ma non identica, con differenze nella gerarchia di suddivisione.
5. Il **GMM** (algoritmo EM) ha offerto un'assegnazione probabilistica dei pixel ai cluster, evidenziando le zone di transizione pedologica con incertezza elevata (pixel con probabilità $< 70\%$). La selezione del modello tramite BIC e AIC ha confermato la ragionevolezza della scelta $K = 6$. I cluster GMM mostrano una struttura spaziale comparabile a quella del K -Means, con confini leggermente più sfumati dovuti alla natura ellissoidale delle componenti gaussiane.
6. Il **Mini-Batch K-Means** ha confermato la scalabilità dell'approccio a dataset geospaziali di grandi dimensioni, con un'accelerazione di circa $3\times$ (0.141 s vs 0.437 s) e un incremento dell'inerzia limitato al 2.4% .

8.2 Limiti dello Studio

- **Assenza di ground-truth:** trattandosi di clustering non supervisionato, non è possibile calcolare metriche esterne basate su etichette reali. La validazione si basa su indici interni (Silhouette, SSE, DB, CH), concordanza tra algoritmi (ARI, NMI) e coerenza spaziale.
- **Risoluzione spaziale:** la griglia SoilGrids a 250 m media le proprietà su pixel relativamente grandi, potendo mascherare variabilità locale.

- **Scelta di K** : la scelta di $K = 6$ è stata guidata da un bilanciamento tra metriche statistiche e conoscenze di dominio agronomico, ma potrebbe beneficiare di una validazione con dati di campo (profili pedologici reali).

8.3 Sviluppi Futuri

Possibili estensioni del lavoro includono:

- L'integrazione di **dati climatici e morfologici** (precipitazioni, pendenza, uso del suolo) come feature aggiuntive.
- L'applicazione di algoritmi di clustering **spazialmente vincolati** che incorporino la prossimità geografica nel calcolo delle distanze.
- L'estensione dell'analisi all'**intera regione Puglia** o al Sud Italia per validare la generalizzabilità dell'approccio.
- L'impiego di tecniche di **deep clustering** (autoencoders + clustering nello spazio latente) per catturare relazioni non lineari tra le feature.