

UNIVERSITÀ DEGLI STUDI DI BRESCIA
DIPARTIMENTO DI INGEGNERIA DELL'INFORMAZIONE

Clustering Pedologico dei Suoli della Capitanata mediante Analisi dei Gradienti Verticali

Progetto per il corso di
Machine Learning e Data Mining (MLDM)
Anno Accademico 2025/2026

Autori:

Mattia Massolari
Matricola: 740458

Marco Mazzardi
Matricola: 741265

Indice

1	Abstract	3
2	Introduzione	3
2.1	Contesto e Motivazione	3
2.2	Obiettivi del Progetto	3
3	Dataset e Ingestione Dati	4
3.1	Fonte dei Dati: SoilGrids	4
3.2	Variabili del Dataset	4
3.3	Pipeline di Ingestione e Integrazione	5
4	Analisi Esplorativa dei Dati (EDA)	6
4.1	Estrazione e Pulizia dello Strato Superficiale	6
4.2	Controlli di Consistenza	6
4.3	Analisi delle Distribuzioni	6
4.4	Matrici di Correlazione	7
5	Feature Engineering: Gradienti Verticali	8
5.1	Motivazione	8
5.2	Delta Totale	8
5.3	Gradienti Normalizzati	9
5.4	Selezione delle 15 Feature Finali	9
5.5	Analisi di Correlazione delle Feature Ingegnerizzate	10
6	Metodologia	11
6.1	Standardizzazione dei Dati	11
6.2	Campionamento per Ottimizzazione	12
6.3	Algoritmo 1: K-Means	12
6.3.1	Ricerca del K Ottimale	12
6.3.2	Forzatura Agronomica a K=5	13
6.4	Algoritmo 2: DBSCAN	13
6.5	Algoritmo 3: Bisecting K-Means	14
6.6	Algoritmo 4: Gaussian Mixture Model (EM)	14
6.7	Riduzione Dimensionale: PCA	15
6.8	Metriche di Validazione	16
7	Risultati Sperimentali	16
7.1	Ricerca del K Ottimale	16
7.2	Visualizzazione Avanzata con Yellowbrick	17

7.3	Proiezione PCA dei Cluster	18
7.4	Mappatura Spaziale dei Cluster	19
7.5	Risultati del GMM (Expectation-Maximization)	20
7.5.1	Selezione del Modello: BIC e AIC	20
7.5.2	Mappatura Spaziale GMM	20
7.6	Profilazione dei Cluster	21
7.7	Validazione e Confronto dei Modelli	22
7.8	Efficienza Computazionale: K-Means vs Mini-Batch K-Means	22
8	Discussione e Conclusioni	23
8.1	Sintesi dei Risultati	23
8.2	Limiti dello Studio	24
8.3	Sviluppi Futuri	24

1 Abstract

Il presente lavoro propone un approccio di clustering non supervisionato per la caratterizzazione pedologica dei suoli della regione Capitanata (Puglia, Italia), basato sull'analisi dei **gradienti verticali** delle proprietà chimico-fisiche del suolo.

A partire dai dati geospaziali SoilGrids, sono state ingegnerizzate feature che descrivono le *dinamiche verticali* del profilo pedologico: tassi di variazione normalizzati (gradienti) tra i sei strati di profondità standard (0–200 cm).

Quattro algoritmi di clustering sono stati addestrati e confrontati: ***K*-Means** (con ricerca iperparametri tramite Optuna, GridSearchCV e Metodo del Gomito), **DBSCAN**, **Bisecting *K*-Means** e **Gaussian Mixture Model (GMM)**, quest'ultimo basato sull'algoritmo Expectation-Maximization (EM) che generalizza il *K*-Means in ambito probabilistico. La validazione è stata condotta mediante Coefficiente di Silhouette e Sum of Squared Error (SSE). Un confronto di efficienza tra *K*-Means standard e Mini-Batch *K*-Means completa l'analisi.

I risultati mostrano che il *K*-Means con $K=5$ produce la migliore separazione spaziale e agronomica dei cluster, identificando tipologie di suolo con dinamiche verticali distinte e coerenti con la geomorfologia del territorio.

2 Introduzione

2.1 Contesto e Motivazione

La conoscenza dettagliata delle proprietà del suolo riveste un ruolo fondamentale per la gestione agricola sostenibile, la pianificazione territoriale e la modellazione ambientale. In particolare, la *variabilità verticale* del profilo pedologico — ovvero il modo in cui le proprietà chimico-fisiche cambiano scendendo in profondità — fornisce informazioni cruciali sulla genesi del suolo, sulla presenza di orizzonti diagnostici (ad esempio orizzonti argillici o suole di lavorazione) e sul potenziale agronomico di un'area.

La regione della **Capitanata**, situata nella provincia di Foggia, rappresenta una delle principali aree agricole d'Italia, caratterizzata da una notevole variabilità pedologica dovuta alla compresenza di alluvioni recenti, argille plioceniche, depositi calcarei e suoli vulcanici.

2.2 Obiettivi del Progetto

L'obiettivo di questo progetto è applicare tecniche di **apprendimento non supervisionato** (clustering) per:

1. **Identificare tipologie pedologiche omogenee** sulla base delle dinamiche verticali delle proprietà del suolo, senza utilizzare etichette predefinite.

2. **Confrontare algoritmi di clustering** di diversa natura: partizionale (K -Means), basato sulla densità (DBSCAN), gerarchico divisivo (Bisecting K -Means) e probabilistico (Gaussian Mixture Model con algoritmo EM).
3. **Validare la coerenza spaziale** dei risultati, verificando che i cluster individuati nello spazio delle feature assumano una distribuzione geografica coerente con la geomorfologia del territorio.

3 Dataset e Ingestione Dati

3.1 Fonte dei Dati: SoilGrids

I dati utilizzati provengono da **SoilGrids** (<https://soilgrids.org>), un sistema globale di mappatura predittiva del suolo sviluppato dall'ISRIC – World Soil Information. SoilGrids fornisce mappe raster a risoluzione di 250 m per le principali proprietà chimico-fisiche del suolo, distribuite su sei strati di profondità standard: 0–5 cm, 5–15 cm, 15–30 cm, 30–60 cm, 60–100 cm e 100–200 cm.

3.2 Variabili del Dataset

Le variabili estratte per l'area della Capitanata sono riepilogate nella Tabella 1.

Tabella 1: Variabili pedologiche utilizzate nel progetto.

Variabile	Descrizione	Unità
clay	Contenuto di argilla	%
sand	Contenuto di sabbia	%
silt	Contenuto di limo	%
soc	Carbonio organico del suolo	g/kg
bdod	Densità apparente	g/cm ³
cfvo	Frammenti grossolani	%
cec	Capacità di scambio cationico	cmol _c /kg
nitrogen	Azoto totale	g/kg
phh2o	pH in acqua	–
ocd	Densità di carbonio organico	kg/m ³
wv0010	Contenuto idrico a 10 kPa	cm ³ /cm ³
wv0033	Contenuto idrico a 33 kPa (CC)	cm ³ /cm ³
wv1500	Contenuto idrico a 1500 kPa (PA)	cm ³ /cm ³
ocs	Stock di carbonio organico	t/ha
Ksat	Conduttività idraulica saturata (derivata)	cm/giorno

3.3 Pipeline di Ingestione e Integrazione

Il dataset di base è stato fornito in formato NetCDF (.nc), già parzialmente convertito nelle corrette unità di misura fisiche. Per le variabili mancanti nel file NetCDF originale (come `cec`, `phh2o`, `ocd`, `nitrogen` e le variabili idriche), sono stati integrati i file raster in formato GeoTIFF (.tif) per ciascuno dei sei strati di profondità.

L'integrazione è avvenuta tramite le seguenti operazioni:

1. **Caricamento** dei file TIF con `rioxarray` e rimozione della dimensione `band`.
2. **Allineamento spaziale** alla griglia del NetCDF mediante interpolazione `nearest-neighbor` (`interp_like`).
3. **Scaling condizionato**: per ogni variabile, un controllo sul valore massimo determina se applicare il fattore di conversione previsto dal README di SoilGrids (es. divisione per 10 per il pH, per 100 per l'azoto).

```

1  for var in variabili_tif:
2      da_depths = []
3      for depth in depths:
4          tif_path = os.path.join(base_dir, f"{var}_{depth}_mean.tif")
5          if os.path.exists(tif_path):
6              da_tif = rioxarray.open_rasterio(tif_path, masked=True)\
7                  .squeeze("band").drop_vars("band")
8              da_tif = da_tif.rename({'x': 'lon', 'y': 'lat'})
9              da_matched = da_tif.interp_like(ds_scaled, method="
              nearest")
10             da_depths.append(da_matched.assign_coords(depth=depth))
11
12  if da_depths:
13      da_3d = xr.concat(da_depths, dim='depth')
14      # Scaling condizionato in base al range osservato
15      if var == 'phh2o' and float(da_3d.max()) > 15:
16          da_3d = da_3d / 10.0
17      elif var == 'nitrogen' and float(da_3d.max()) > 100:
18          da_3d = da_3d / 100.0
19      ds_scaled[var] = da_3d

```

Listing 1: Integrazione dei file TIF con scaling condizionato.

4 Analisi Esplorativa dei Dati (EDA)

4.1 Estrazione e Pulizia dello Strato Superficiale

L'EDA è stata condotta sullo strato superficiale (0–5 cm), selezionando 13 variabili tra fisiche (`clay`, `sand`, `silt`, `bdod`, `soc`, `cfvo`) e chimico-idrologiche (`cec`, `nitrogen`, `phh2o`, `ocd`, `wv0010`, `wv0033`, `wv1500`).

I dati sono stati sottoposti a una pipeline di pulizia articolata in:

- **Rimozione pixel No-Data e mare:** esclusione dei pixel con valori nulli o zero fittizi per variabili che non possono fisicamente assumere valore zero (pH, densità, frazioni granulometriche).
- **Vincoli fisici:** limiti superiori coerenti con la realtà ($\text{pH} \leq 14$, frazioni $\leq 100\%$, densità $\leq 2.8 \text{ g/cm}^3$).
- **Trimming statistico:** per le variabili prive di limiti fisici noti, rimozione dei valori oltre il 99.9° percentile.

4.2 Controlli di Consistenza

Due verifiche aggiuntive garantiscono la coerenza interna del dataset:

1. **Consistenza granulometrica:** la somma argilla + sabbia + limo deve avvicinarsi al 100%:

$$\text{clay}_{0-5} + \text{sand}_{0-5} + \text{silt}_{0-5} \approx 100\%$$

2. **Consistenza idrologica:** la Capacità di Campo (CC, misurata a 33 kPa) deve essere superiore al Punto di Appassimento Permanente (PA, a 1500 kPa):

$$\theta_{33} > \theta_{1500}$$

Le inversioni anomale sono state conteggiate e segnalate.

4.3 Analisi delle Distribuzioni

Le distribuzioni delle 13 variabili sono state visualizzate mediante istogrammi con sovrapposizione della stima kernel di densità (KDE).




Figura 1: Distribuzioni delle variabili pedologiche nello strato superficiale (0–5 cm). Le curve KDE evidenziano eventuali asimmetrie e multimodalità.

4.4 Matrice di Correlazione

La matrice di correlazione completa (Figura 2) ha evidenziato le relazioni attese tra le variabili:

- Correlazione **positiva forte** tra **soc** e **cec**: la sostanza organica contribuisce significativamente alla capacità di scambio cationico.
- Correlazione **negativa** tra **clay** e **sand**: la complementarità granulometrica.

- Correlazione **positiva** tra le variabili idriche (wv0010, wv0033, wv1500): coerenza della ritenzione idrica.




Figura 2: Matrice di correlazione delle variabili pedologiche superficiali. I valori numerici sono annotati nella heatmap `coolwarm`.

5 Feature Engineering: Gradienti Verticali

5.1 Motivazione

Un clustering basato sulle sole variabili superficiali cattura solo un'istantanea bidimensionale del suolo. Per cogliere la complessità del profilo pedologico, è necessario descrivere *come* le proprietà cambiano con la profondità. A tal fine, sono state ingegnerizzate due tipologie di feature verticali.

5.2 Delta Totale

Il **delta totale** misura la variazione netta tra il fondo (100–200 cm) e la superficie (0–5 cm) del profilo:

$$\Delta_{\text{tot}}^{(v)} = X_{100-200}^{(v)} - X_{0-5}^{(v)} \quad (1)$$

dove v indica la variabile pedologica. Un Δ_{tot} positivo per l'argilla, ad esempio, indica un accumulo in profondità tipico di suoli con orizzonte argilloso (Bt).

5.3 Gradienti Normalizzati

Il **gradiente normalizzato** quantifica il tasso di variazione tra due strati consecutivi, normalizzato per la distanza (in cm) tra i centri degli strati:

$$g_{i \rightarrow i+1}^{(v)} = \frac{X_{d_{i+1}}^{(v)} - X_{d_i}^{(v)}}{z_{i+1} - z_i} \quad (2)$$

dove z_i e z_{i+1} sono i punti medi (in cm) dei due strati. I punti medi utilizzati sono: 2.5, 10.0, 22.5, 45.0, 80.0 e 150.0 cm (Tabella 2).

Tabella 2: Punti medi degli strati di profondità SoilGrids.

Strato	Punto medio (cm)
0–5 cm	2.5
5–15 cm	10.0
15–30 cm	22.5
30–60 cm	45.0
60–100 cm	80.0
100–200 cm	150.0

Questa normalizzazione è fondamentale perché gli strati SoilGrids hanno spessori diversi (5, 10, 15, 30, 40 e 100 cm): senza normalizzazione, il gradiente tra 60–100 cm e 100–200 cm (distanza di 70 cm tra i centri) non sarebbe comparabile con quello tra 0–5 cm e 5–15 cm (distanza di 7.5 cm).

5.4 Selezione delle 15 Feature Finali

Dopo il calcolo, sono state selezionate le feature suddivise in gruppi tematici (Tabella 3). Oltre alle variabili pedologiche classiche, è stata inclusa la **conduttività idraulica saturata** (K_{sat}), già presente nel dataset NetCDF in quanto derivata mediante funzioni di pedotrasferimento a partire dalle variabili tessiturali e idrologiche.

Tabella 3: Feature selezionate per il clustering, raggruppate per tipologia.

Gruppo	Feature	Interpretazione
Argilla	clay_grad_0-5_to_5-15	Dinamica tessiturale superficiale
	clay_grad_5-15_to_15-30	Inizio lisciviazione argilla
	clay_grad_15-30_to_30-60	Orizzonte argillico (Bt)
Sabbia	sand_grad_30-60_to_60-100	Discontinuità sedimentarie
SOScheletro	cfvo_grad_15-30_to_30-60	Transizioni litologiche
	cfvo_grad_60-100_to_100-200	Contatto con roccia madre
SOC	soc_grad_0-5_to_5-15	Crollo iniziale sost. organica
	soc_grad_5-15_to_15-30	Esaurimento zona radicale
BDOD	bdod_grad_5-15_to_15-30	Suola di aratura
	bdod_grad_15-30_to_30-60	Compattazione profonda
	bdod_grad_30-60_to_60-100	Transizione substrato
Ksat	Ksat_grad_0-5_to_5-15	Variazione drenaggio superficiale
	Ksat_grad_15-30_to_30-60	Variazione drenaggio profondo

5.5 Analisi di Correlazione delle Feature Ingegnerizzate

Le correlazioni tra le feature ingegnerizzate sono state analizzate separatamente per ciascun gruppo tematico. In particolare:

- I **delta macro** confermano la correlazione attesa tra CEC e SOC (la capacità di scambio cationico è legata alla materia organica).
- Le **transizioni superficiali** mostrano correlazione negativa tra il gradiente SOC e il gradiente BDOD (dove la sostanza organica cala, la densità aumenta).
- Le **dinamiche profonde** evidenziano il legame tra accumulo di argilla e aumento della CEC in profondità.





Figura 3: Matrice di correlazione dei delta totali (fondo – superficie) per le 5 variabili principali.



(a) Transizioni superficiali (0–30 cm).

(b) Dinamiche profonde (30–200 cm).

Figura 4: Correlazione dei gradienti normalizzati per zona di profondità.

6 Metodologia

6.1 Standardizzazione dei Dati

Le 15 feature selezionate presentano scale e deviazioni standard molto diverse (ad esempio, il pH varia tra 4 e 9, mentre la CEC può superare 50 cmol_c/kg). Per evitare che le variabili a scala maggiore dominino il calcolo delle distanze euclidee, è stato applicato uno **StandardScaler**:

$$\tilde{x}_j = \frac{x_j - \mu_j}{\sigma_j} \quad (3)$$

dove μ_j e σ_j sono rispettivamente la media e la deviazione standard della j -esima feature sul dataset completo.

6.2 Campionamento per Ottimizzazione

Per rendere computazionalmente fattibile la ricerca degli iperparametri (in particolare il calcolo del Coefficiente di Silhouette, che ha complessità $O(n^2)$), è stato estratto un campione casuale stratificato di **15 000 pixel** dal dataset standardizzato.

6.3 Algoritmo 1: K-Means

L'algoritmo K -Means partiziona n osservazioni in K cluster minimizzando la **Sum of Squared Errors** (SSE) intra-cluster:

$$\text{SSE} = \sum_{k=1}^K \sum_{\mathbf{x}_i \in C_k} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2 \quad (4)$$

dove $\boldsymbol{\mu}_k$ è il centroide del cluster C_k .

6.3.1 Ricerca del K Ottimale

La determinazione del numero ottimale di cluster è stata affrontata con quattro strategie complementari:

1. **Ottimizzazione Bayesiana (Optuna)**: ricerca nello spazio degli iperparametri ($K \in [2, 12]$, $\text{n_init} \in \{10, 20\}$, $\text{max_iter} \in [200, 500]$, $\text{init} \in \{\text{k-means++}, \text{random}\}$) per massimizzare il Coefficiente di Silhouette, con 20 trial.
2. **GridSearchCV**: esplorazione esaustiva con validazione incrociata “leave-all-in” (split unico) su $K \in [2, 12]$.
3. **Metodo del Gomito**: identificazione del punto di flesso nella curva di inerzia mediante calcolo della distanza massima dalla retta che congiunge i punti estremi.
4. **Silhouette Standard**: massimizzazione del Coefficiente di Silhouette al variare di K .

I risultati dei quattro metodi sono stati aggregati con un **sistema di voto a maggioranza**: il K proposto più frequentemente viene adottato; in caso di parità, si sceglie la mediana dei candidati.

```

1 def objective(trial):
2     n_clusters = trial.suggest_int('n_clusters', 2, 12)
3     n_init = trial.suggest_categorical('n_init', [10, 20])
4     max_iter = trial.suggest_int('max_iter', 200, 500, step=100)
5     init = trial.suggest_categorical('init', ['k-means++', 'random'])
6
7     model = KMeans(n_clusters=n_clusters, n_init=n_init,
8                   max_iter=max_iter, init=init, random_state=42)
9     labels = model.fit_predict(X_search)
10    return silhouette_score(X_search, labels)
11
12 study = optuna.create_study(direction='maximize')
13 study.optimize(objective, n_trials=20)

```

Listing 2: Ricerca iperparametri con Optuna.

6.3.2 Forzatura Agronomica a $K=5$

Sebbene metriche come la Silhouette tendano a favorire valori bassi di K (ad esempio $K = 2$), che producono una separazione binaria del territorio, da un punto di vista agronomico è opportuno cogliere sfumature più fini (ad esempio, distinguere tra argille reattive e inattive, o tra suoli con diverso grado di lisciviazione).

Sulla base del Metodo del Gomito e di considerazioni pedologiche, il modello finale è stato addestrato con $K=5$.

6.4 Algoritmo 2: DBSCAN

Il **DBSCAN** (Density-Based Spatial Clustering of Applications with Noise) identifica cluster come regioni ad alta densità separate da regioni a bassa densità, classificando come *rumore* (-1) i punti isolati.

Due sono i parametri chiave:

- ε (**eps**): raggio massimo del vicinato.
- **min_samples**: numero minimo di punti per formare un nucleo denso.

La determinazione di ε è stata effettuata tramite il **grafico K-NN distance**: calcolando la distanza dal k -esimo vicino più prossimo (con $k = \text{min_samples} = 26$) e ordinando i valori in modo crescente, si individua il punto di ginocchio che segna il passaggio da “densità intra-cluster” a “distanza inter-cluster”. Il valore scelto è stato $\varepsilon = 1.9$.




Figura 5: Grafico delle distanze K-NN per la determinazione dell'epsilon ottimale del DBSCAN.

6.5 Algoritmo 3: Bisecting K-Means

Il **Bisecting K-Means** è un approccio gerarchico *divisivo* (top-down): parte da un unico macro-cluster e lo suddivide iterativamente in due sotto-cluster fino a raggiungere il numero desiderato di partizioni.

A ogni iterazione, il cluster con la varianza interna maggiore viene selezionato e bipartito con un K-Means a $K = 2$. Il processo è stato configurato con $K = 5$ per garantire un confronto equo con il K-Means standard.

6.6 Algoritmo 4: Gaussian Mixture Model (EM)

Il **Gaussian Mixture Model** (GMM) generalizza il K-Means in ambito probabilistico, modellando i dati come una miscela di K distribuzioni gaussiane multivariate:

$$p(\mathbf{x}) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x} \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \quad (5)$$

dove π_k sono i pesi di miscelazione ($\sum_k \pi_k = 1$), $\boldsymbol{\mu}_k$ e $\boldsymbol{\Sigma}_k$ sono la media e la matrice di covarianza della k -esima componente gaussiana.

I parametri vengono stimati mediante l'algoritmo iterativo **Expectation-Maximization (EM)**:

1. **E-step (Expectation)**: per ogni campione $\mathbf{x}_i$, si calcola la *responsabilità* γ_{ik} , ovvero la probabilità a posteriori che $\mathbf{x}_i$ appartenga alla componente k :

$$\gamma_{ik} = \frac{\pi_k \mathcal{N}(\mathbf{x}_i \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(\mathbf{x}_i \mid \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)} \quad (6)$$

2. **M-step (Maximization)**: si aggiornano i parametri di ogni componente usando le responsabilità come pesi:

$$\boldsymbol{\mu}_k^{\text{new}} = \frac{\sum_i \gamma_{ik} \mathbf{x}_i}{\sum_i \gamma_{ik}} \quad (7)$$

$$\boldsymbol{\Sigma}_k^{\text{new}} = \frac{\sum_i \gamma_{ik} (\mathbf{x}_i - \boldsymbol{\mu}_k^{\text{new}})(\mathbf{x}_i - \boldsymbol{\mu}_k^{\text{new}})^\top}{\sum_i \gamma_{ik}} \quad (8)$$

$$\pi_k^{\text{new}} = \frac{1}{n} \sum_i \gamma_{ik} \quad (9)$$

L'iterazione prosegue fino a convergenza della log-verosimiglianza. Rispetto al K -Means, il GMM offre due vantaggi fondamentali:

- **Assegnazione probabilistica** (*soft clustering*): ogni pixel riceve una probabilità di appartenenza a ciascun cluster, piuttosto che un'assegnazione deterministica. Questo è particolarmente utile in pedologia, dove le transizioni tra tipi di suolo sono graduali.
- **Cluster ellissoidali**: la matrice di covarianza completa consente di modellare cluster non sferici, catturando correlazioni tra le feature.

Per la selezione del numero ottimale di componenti, sono stati utilizzati il **Bayesian Information Criterion (BIC)** e l'**Akaike Information Criterion (AIC)**:

$$\text{BIC} = -2 \ln \hat{L} + p \ln n \quad (10)$$

$$\text{AIC} = -2 \ln \hat{L} + 2p \quad (11)$$

dove $\hat{L}$ è la verosimiglianza massimizzata, p il numero di parametri liberi e n la dimensione del campione. Entrambi i criteri penalizzano la complessità del modello, ma il BIC impone una penalità più severa, tendendo a preferire modelli più parsimoniosi.

Il modello finale è stato configurato con `covariance_type='full'` (matrice di covarianza completa per ogni componente) e $K = 5$ per consentire un confronto equo con gli altri algoritmi.

6.7 Riduzione Dimensionale: PCA

Per la **visualizzazione** dei cluster nello spazio delle feature (15 dimensioni), è stata applicata un'analisi delle Componenti Principali (PCA) per proiettare i dati in 2D:

$$\mathbf{z}_i = \mathbf{W}^\top \tilde{\mathbf{x}}_i \quad (12)$$

dove $\mathbf{W} \in \mathbb{R}^{15 \times 2}$ è la matrice delle prime due componenti principali, calcolate come gli autovettori associati ai due autovalori maggiori della matrice di covarianza.

6.8 Metriche di Validazione

La validazione dei modelli è stata condotta con due metriche interne (non richiedono etichette ground-truth):

Coefficiente di Silhouette. Per ogni campione i :

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \quad (13)$$

dove $a(i)$ è la distanza media intra-cluster e $b(i)$ è la distanza media al cluster più vicino. Il valore medio $\bar{s} \in [-1, 1]$: valori prossimi a 1 indicano cluster ben separati.

Nota metodologica: per il DBSCAN, il Coefficiente di Silhouette è stato calcolato *escludendo* i punti classificati come rumore (etichetta -1). Includere tali punti penalizzerebbe artificialmente l'algoritmo, poiché i punti di rumore non appartengono ad alcun cluster e generano valori di silhouette fortemente negativi, distorcendo la media complessiva.

Sum of Squared Error (SSE / Inerzia). Definita nell'Eq. (4), misura la coesione interna dei cluster. Un valore più basso indica cluster più compatti. Questa metrica non è applicabile al DBSCAN né al GMM (che ottimizza la verosimiglianza anziché l'SSE).

BIC e AIC. Per il GMM, la selezione del modello è stata guidata dal BIC e dall'AIC (cfr. Sezione 6.6), che bilanciano bontà del fit e complessità.




7 Risultati Sperimentali

7.1 Ricerca del K Ottimale


I risultati della ricerca iperparametri sono sintetizzati nella Tabella 4.

Tabella 4: Riepilogo dei valori di K suggeriti dai quattro metodi.

Metodo	K suggerito
Silhouette Standard	2
Metodo del Gomito	5
GridSearchCV	2
Optuna	2
K finale (voto)	5

(a) Curva del gomito (Inerzia vs K).(b) Coefficiente di Silhouette vs K .Figura 6: Metriche per la selezione del K ottimale.

(a) Storia dell'ottimizzazione Optuna.



(b) Importanza degli iperparametri (Optuna).

Figura 7: Analisi dell'ottimizzazione bayesiana con Optuna.

7.2 Visualizzazione Avanzata con Yellowbrick

La libreria Yellowbrick ha fornito tre visualizzazioni diagnostiche:




Figura 8: Distanza inter-cluster (Yellowbrick) per la validazione del clustering.

7.3 Proiezione PCA dei Cluster

La Figura 9 mostra la proiezione dei cluster nello spazio delle prime due componenti principali.




Figura 9: Proiezione PCA 2D dei cluster *K*-Means. Le percentuali sugli assi indicano la varianza spiegata da ciascuna componente.

7.4 Mappatura Spaziale dei Cluster

Nonostante l'algoritmo non abbia ricevuto informazioni spaziali (coordinate geografiche), i cluster assumono una distribuzione geografica coerente con la geomorfologia della Capitanata (Figura 10).





Figura 10: Mappatura spaziale dei cluster K -Means con $K=5$ sulla regione Capitanata. La coerenza geografica dei cluster conferma la validità pedologica dell'analisi.



(a) DBSCAN ($\varepsilon = 1.9$, $\text{min_samples}=26$).

(b) Bisecting K -Means ($K = 5$).

Figura 11: Confronto delle mappature spaziali per DBSCAN e Bisecting K -Means.

7.5 Risultati del GMM (Expectation-Maximization)

7.5.1 Selezione del Modello: BIC e AIC

La Figura 12 mostra l'andamento di BIC e AIC al variare del numero di componenti gaussiane. Entrambi i criteri decrescono all'aumentare di K , con un rallentamento della discesa intorno a $K = 5$, confermando la scelta del modello a 5 componenti.




Figura 12: Curve BIC e AIC per il GMM al variare del numero di componenti. La linea tratteggiata rossa indica $K = 5$.

7.5.2 Mappatura Spaziale GMM

La Figura 13 mostra la mappatura dei cluster GMM. Rispetto al K -Means, il GMM tende a produrre confini inter-cluster più sfumati, coerentemente con la natura probabilistica dell'assegnazione. L'analisi dell'incertezza ha evidenziato la percentuale di pixel con probabilità di assegnazione inferiore al 70%, corrispondenti alle zone di transizione pedologica.




Figura 13: Mappatura spaziale dei cluster GMM con $K=5$. L’assegnazione è basata sulla componente gaussiana con probabilità a posteriori massima (*hard assignment*).

7.6 Profilazione dei Cluster

La heatmap dei centroidi standardizzati (Z-score) permette di interpretare il “profilo agronomico” di ciascun cluster (Figura 14).




Figura 14: Profilo agronomico dei cluster basato sugli Z-score dei centroidi. Valori positivi (rossi) indicano gradienti superiori alla media regionale; valori negativi (blu) indicano gradienti inferiori.

7.7 Validazione e Confronto dei Modelli

La Tabella 5 riporta il confronto quantitativo tra i quattro algoritmi. Si noti che per il DBSCAN il Coefficiente di Silhouette è stato calcolato escludendo i punti di rumore (cfr. Sezione 6).

Tabella 5: Confronto delle metriche di validazione interna ($N = 89\,786$ pixel validi).

Algoritmo	Silhouette ($\uparrow$)	SSE / Inerzia ($\downarrow$)
K-Means ($K = 5$)	0.1050	797 772.04
Bisecting K-Means ($K = 5$)	0.0888	818 668.38
DBSCAN ($\varepsilon = 1.9$)	0.0869*	N/A
GMM / EM ($K = 5$)	0.0692	N/A [†]

*Calcolato escludendo i 5 570 pixel (6.20%) classificati come rumore (-1).

[†]Il GMM ottimizza la log-verosimiglianza ($BIC = 2\,792\,738$, $AIC = 2\,787\,810$), non l'SSE.

7.8 Efficienza Computazionale: K-Means vs Mini-Batch K-Means

Per valutare la scalabilità dell'approccio su dataset geospaziali di grandi dimensioni, è stato condotto un confronto tra K -Means standard e **Mini-Batch K -Means** (Tabella 6).

Il Mini-Batch K -Means elabora i dati a blocchi di dimensione fissa (`batch_size` = 1024), aggiornando i centroidi in modo incrementale. Questo approccio riduce drasticamente il tempo di addestramento con un trade-off minimo in termini di inerzia.

Tabella 6: Confronto efficienza su 89 786 pixel validi della Capitanata.

Algoritmo	Tempo (s) ($\downarrow$)	Inerzia ($\downarrow$)
K-Means Standard	0.472	797 772.53
Mini-Batch K-Means	0.136	814 878.06

8 Discussione e Conclusioni

8.1 Sintesi dei Risultati

Il lavoro ha dimostrato che l’approccio basato sui **gradienti verticali** consente di superare i limiti del clustering bidimensionale, catturando informazioni sulla struttura tridimensionale del profilo pedologico. I principali risultati sono:

1. La **feature engineering** basata su gradienti normalizzati si è dimostrata efficace nel catturare le dinamiche verticali del suolo, producendo cluster con interpretazione agronomica chiara.
2. Il **K -Means** con $K=5$ ha prodotto la migliore separazione spaziale, con cluster geograficamente coerenti con la geomorfologia della Capitanata.
3. Il **DBSCAN** ha classificato una porzione significativa di pixel come rumore, confermando che la distribuzione dei dati nello spazio dei gradienti non è caratterizzata da cluster a densità nettamente diversa, ma piuttosto da regioni a densità omogenea (scenario favorevole al K -Means).
4. Il **Bisecting K -Means** ha fornito risultati comparabili al K -Means standard, con una lieve differenza nella gerarchia di suddivisione che potrebbe essere sfruttata per analisi a risoluzione variabile.
5. Il **GMM** (algoritmo EM) ha offerto un’assegnazione probabilistica dei pixel ai cluster, evidenziando le zone di transizione pedologica con incertezza elevata. La selezione del modello tramite BIC e AIC ha confermato la ragionevolezza della scelta $K = 5$. I cluster GMM mostrano una struttura spaziale comparabile a quella del K -Means, con confini leggermente più sfumati dovuti alla natura ellissoidale delle componenti gaussiane.

6. Il **Mini-Batch K -Means** ha confermato la scalabilità dell'approccio a dataset geospaziali di grandi dimensioni, con un'accelerazione significativa e una perdita di inerzia trascurabile.

8.2 Limiti dello Studio

- **Assenza di ground-truth:** trattandosi di clustering non supervisionato, non è possibile calcolare metriche esterne (Adjusted Rand Index, NMI). La validazione si basa su indici interni e coerenza spaziale.
- **Risoluzione spaziale:** la griglia SoilGrids a 250 m media le proprietà su pixel relativamente grandi, potendo mascherare variabilità locale.
- **Scelta di K :** la forzatura agronomica del K è stata guidata da conoscenze di dominio, ma potrebbe beneficiare di una validazione con dati di campo.

8.3 Sviluppi Futuri

Possibili estensioni del lavoro includono:

- L'integrazione di **dati climatici e morfologici** (precipitazioni, pendenza, uso del suolo) come feature aggiuntive.
- L'applicazione di algoritmi di clustering **spazialmente vincolati** che incorporino la prossimità geografica nel calcolo delle distanze.
- L'estensione dell'analisi all'**intera regione Puglia** o al Sud Italia per validare la generalizzabilità dell'approccio.
- L'impiego di tecniche di **deep clustering** (autoencoders + clustering nello spazio latente) per catturare relazioni non lineari tra le feature.