

UNIVERSITÀ DEGLI STUDI DI FOGGIA
DIPARTIMENTO DI ECONOMIA, MANAGEMENT E
TERRITORIO

**Clustering Pedologico dei Suoli
della Capitanata mediante Analisi
dei Gradienti Verticali**

Progetto per il corso di
Machine Learning e Data Mining (MLDM)
Anno Accademico 2025/2026

Autore:
Mattia Massolari

Docente:

Settembre 2026

Indice

1	Abstract	2
2	Introduzione	2
2.1	Contesto e Motivazione	2
2.2	Obiettivi del Progetto	2
2.3	Struttura della Relazione	3
3	Dataset e Ingestione Dati	3
3.1	Fonte dei Dati: SoilGrids	3
3.2	Variabili del Dataset	3
3.3	Pipeline di Ingestione e Integrazione	4
4	Analisi Esplorativa dei Dati (EDA)	5
4.1	Estrazione e Pulizia dello Strato Superficiale	5
4.2	Controlli di Consistenza	5
4.3	Analisi delle Distribuzioni	6
4.4	Matrice di Correlazione	6
5	Feature Engineering: Gradienti Verticali	7
5.1	Motivazione	7
5.2	Delta Totale	7
5.3	Gradienti Normalizzati	8
5.4	Selezione delle 15 Feature Finali	8
5.5	Analisi di Correlazione delle Feature Ingegnerizzate	9
6	Metodologia	10
6.1	Standardizzazione dei Dati	10
6.2	Campionamento per Ottimizzazione	11
6.3	Algoritmo 1: K-Means	11
6.3.1	Ricerca del K Ottimale	11
6.3.2	Forzatura Agronomica a K=5	12
6.4	Algoritmo 2: DBSCAN	12
6.5	Algoritmo 3: Bisecting K-Means	13
6.6	Riduzione Dimensionale: PCA	13
6.7	Metriche di Validazione	13
7	Risultati Sperimentali	14
7.1	Ricerca del K Ottimale	14
7.2	Visualizzazione Avanzata con Yellowbrick	15

7.3	Proiezione PCA dei Cluster	15
7.4	Mappatura Spaziale dei Cluster	16
7.5	Profilazione dei Cluster	18
7.6	Validazione e Confronto dei Modelli	18
7.7	Efficienza Computazionale: K-Means vs Mini-Batch K-Means	19
8	Discussione e Conclusioni	19
8.1	Sintesi dei Risultati	19
8.2	Limiti dello Studio	20
8.3	Sviluppi Futuri	20

1 Abstract

Il presente lavoro propone un approccio di clustering non supervisionato per la caratterizzazione pedologica dei suoli della regione Capitanata (Puglia, Italia), basato sull'analisi dei **gradienti verticali** delle proprietà chimico-fisiche del suolo.

A partire dai dati geospaziali SoilGrids, sono state ingegnerizzate 15 feature che descrivono le *dinamiche verticali* del profilo pedologico: variazioni totali (delta) e tassi di variazione normalizzati (gradienti) tra i sei strati di profondità standard (0–200 cm).

Tre algoritmi di clustering sono stati addestrati e confrontati: **K-Means** (con ricerca iperparametri tramite Optuna, GridSearchCV e Metodo del Gomito), **DBSCAN** e **Bisecting K-Means**. La validazione è stata condotta mediante Coefficiente di Silhouette e Sum of Squared Error (SSE). Un confronto di efficienza tra *K-Means* standard e Mini-Batch *K-Means* completa l'analisi.

I risultati mostrano che il *K-Means* con $K=5$ produce la migliore separazione spaziale e agronomica dei cluster, identificando tipologie di suolo con dinamiche verticali distinte e coerenti con la geomorfologia del territorio.

2 Introduzione

2.1 Contesto e Motivazione

La conoscenza dettagliata delle proprietà del suolo riveste un ruolo fondamentale per la gestione agricola sostenibile, la pianificazione territoriale e la modellazione ambientale. In particolare, la *variabilità verticale* del profilo pedologico — ovvero il modo in cui le proprietà chimico-fisiche cambiano scendendo in profondità — fornisce informazioni cruciali sulla genesi del suolo, sulla presenza di orizzonti diagnostici (ad esempio orizzonti argillici o suole di lavorazione) e sul potenziale agronomico di un'area.

La regione della **Capitanata**, situata nella provincia di Foggia, rappresenta una delle principali aree agricole d'Italia, caratterizzata da una notevole variabilità pedologica dovuta alla compresenza di alluvioni recenti, argille plioceniche, depositi calcarei e suoli vulcanici.

2.2 Obiettivi del Progetto

L'obiettivo di questo progetto è applicare tecniche di **apprendimento non supervisionato** (clustering) per:

1. **Identificare tipologie pedologiche omogenee** sulla base delle dinamiche verticali delle proprietà del suolo, senza utilizzare etichette predefinite.

2. **Confrontare algoritmi di clustering** di diversa natura: partizionale (K -Means), basato sulla densità (DBSCAN) e gerarchico divisivo (Bisecting K -Means).
3. **Validare la coerenza spaziale** dei risultati, verificando che i cluster individuati nello spazio delle feature assumano una distribuzione geografica coerente con la geomorfologia del territorio.

2.3 Struttura della Relazione

La relazione è organizzata come segue: la Sezione 3 descrive il dataset e la pipeline di ingestione dati; la Sezione 4 presenta l'analisi esplorativa; la Sezione 5 illustra il processo di feature engineering; la Sezione 6 dettaglia gli algoritmi impiegati e la ricerca degli iperparametri; la Sezione 7 riporta i risultati sperimentali; la Sezione 8 conclude il lavoro con una discussione critica e prospettive future.

3 Dataset e Ingestione Dati

3.1 Fonte dei Dati: SoilGrids

I dati utilizzati provengono da **SoilGrids** (<https://soilgrids.org>), un sistema globale di mappatura predittiva del suolo sviluppato dall'ISRIC – World Soil Information. SoilGrids fornisce mappe raster a risoluzione di 250 m per le principali proprietà chimico-fisiche del suolo, distribuite su sei strati di profondità standard: 0–5 cm, 5–15 cm, 15–30 cm, 30–60 cm, 60–100 cm e 100–200 cm.

3.2 Variabili del Dataset

Le variabili estratte per l'area della Capitanata sono riepilogate nella Tabella 1.

Tabella 1: Variabili pedologiche utilizzate nel progetto.

Variabile	Descrizione	Unità
clay	Contenuto di argilla	%
sand	Contenuto di sabbia	%
silt	Contenuto di limo	%
soc	Carbonio organico del suolo	g/kg
bdod	Densità apparente	g/cm ³
cfvo	Frammenti grossolani	%
cec	Capacità di scambio cationico	cmol _c /kg
nitrogen	Azoto totale	g/kg
phh2o	pH in acqua	—
ocd	Densità di carbonio organico	kg/m ³
wv0010	Contenuto idrico a 10 kPa	cm ³ /cm ³
wv0033	Contenuto idrico a 33 kPa (CC)	cm ³ /cm ³
wv1500	Contenuto idrico a 1500 kPa (PA)	cm ³ /cm ³
ocs	Stock di carbonio organico	t/ha

3.3 Pipeline di Ingestione e Integrazione

Il dataset di base è stato fornito in formato NetCDF (.nc), già parzialmente convertito nelle corrette unità di misura fisiche. Per le variabili mancanti nel file NetCDF originale (come `cec`, `phh2o`, `ocd`, `nitrogen` e le variabili idriche), sono stati integrati i file raster in formato GeoTIFF (.tif) per ciascuno dei sei strati di profondità.

L'integrazione è avvenuta tramite le seguenti operazioni:

1. **Caricamento** dei file TIF con `rioxarray` e rimozione della dimensione `band`.
2. **Allineamento spaziale** alla griglia del NetCDF mediante interpolazione nearest-neighbor (`interp_like`).
3. **Scaling condizionato**: per ogni variabile, un controllo sul valore massimo determina se applicare il fattore di conversione previsto dal README di SoilGrids (es. divisione per 10 per il pH, per 100 per l'azoto).

```

1 for var in variabili_tif:
2     da_depths = []
3     for depth in depths:
4         tif_path = os.path.join(base_dir, f"{var}_{depth}_mean.tif")
5         if os.path.exists(tif_path):
6             da_tif = rioxarray.open_rasterio(tif_path, masked=True)\

```

```

7         .squeeze("band").drop_vars("band")
8     da_tif = da_tif.rename({'x': 'lon', 'y': 'lat'})
9     da_matched = da_tif.interp_like(ds_scaled, method="
        nearest")
10    da_depths.append(da_matched.assign_coords(depth=depth))
11
12    if da_depths:
13        da_3d = xr.concat(da_depths, dim='depth')
14        # Scaling condizionato in base al range osservato
15        if var == 'phh2o' and float(da_3d.max()) > 15:
16            da_3d = da_3d / 10.0
17        elif var == 'nitrogen' and float(da_3d.max()) > 100:
18            da_3d = da_3d / 100.0
19        ds_scaled[var] = da_3d

```

Listing 1: Integrazione dei file TIF con scaling condizionato.

4 Analisi Esplorativa dei Dati (EDA)

4.1 Estrazione e Pulizia dello Strato Superficiale

L'EDA è stata condotta sullo strato superficiale (0–5 cm), selezionando 13 variabili tra fisiche (clay, sand, silt, bdod, soc, cfvo) e chimico-idrologiche (cec, nitrogen, phh2o, ocd, wv0010, wv0033, wv1500).

I dati sono stati sottoposti a una pipeline di pulizia articolata in:

- **Rimozione pixel No-Data e mare:** esclusione dei pixel con valori nulli o zero fittizi per variabili che non possono fisicamente assumere valore zero (pH, densità, frazioni granulometriche).
- **Vincoli fisici:** limiti superiori coerenti con la realtà ($\text{pH} \leq 14$, frazioni $\leq 100\%$, densità $\leq 2.8 \text{ g/cm}^3$).
- **Trimming statistico:** per le variabili prive di limiti fisici noti, rimozione dei valori oltre il 99.9° percentile.

4.2 Controlli di Consistenza

Due verifiche aggiuntive garantiscono la coerenza interna del dataset:

1. **Consistenza granulometrica:** la somma argilla + sabbia + limo deve avvicinarsi al 100%:

$$\text{clay}_{0-5} + \text{sand}_{0-5} + \text{silt}_{0-5} \approx 100\%$$

2. **Consistenza idrologica:** la Capacità di Campo (CC, misurata a 33 kPa) deve essere superiore al Punto di Appassimento Permanente (PA, a 1500 kPa):

$$\theta_{33} > \theta_{1500}$$

Le inversioni anomale sono state conteggiate e segnalate.

4.3 Analisi delle Distribuzioni

Le distribuzioni delle 13 variabili sono state visualizzate mediante istogrammi con sovrapposizione della stima kernel di densità (KDE).




Figura 1: Distribuzioni delle variabili pedologiche nello strato superficiale (0–5 cm). Le curve KDE evidenziano eventuali asimmetrie e multimodalità.

4.4 Matrice di Correlazione

La matrice di correlazione completa (Figura 2) ha evidenziato le relazioni attese tra le variabili:

- Correlazione **positiva forte** tra **soc** e **cec**: la sostanza organica contribuisce significativamente alla capacità di scambio cationico.
- Correlazione **negativa** tra **clay** e **sand**: la complementarità granulometrica.
- Correlazione **positiva** tra le variabili idriche (**wv0010**, **wv0033**, **wv1500**): coerenza della ritenzione idrica.




Figura 2: Matrice di correlazione delle variabili pedologiche superficiali. I valori numerici sono annotati nella heatmap `coolwarm`.

5 Feature Engineering: Gradienti Verticali

5.1 Motivazione

Un clustering basato sulle sole variabili superficiali cattura solo un'istantanea bidimensionale del suolo. Per cogliere la complessità del profilo pedologico, è necessario descrivere *come* le proprietà cambiano con la profondità. A tal fine, sono state ingegnerizzate due tipologie di feature verticali.

5.2 Delta Totale

Il **delta totale** misura la variazione netta tra il fondo (100–200 cm) e la superficie (0–5 cm) del profilo:

$$\Delta_{\text{tot}}^{(v)} = X_{100-200}^{(v)} - X_{0-5}^{(v)} \quad (1)$$

dove v indica la variabile pedologica. Un Δ_{tot} positivo per l'argilla, ad esempio, indica un accumulo in profondità tipico di suoli con orizzonte argillico (Bt).

5.3 Gradienti Normalizzati

Il **gradiente normalizzato** quantifica il tasso di variazione tra due strati consecutivi, normalizzato per la distanza (in cm) tra i centri degli strati:

$$g_{i \rightarrow i+1}^{(v)} = \frac{X_{d_{i+1}}^{(v)} - X_{d_i}^{(v)}}{z_{i+1} - z_i} \quad (2)$$

dove z_i e z_{i+1} sono i punti medi (in cm) dei due strati. I punti medi utilizzati sono: 2.5, 10.0, 22.5, 45.0, 80.0 e 150.0 cm (Tabella 2).

Tabella 2: Punti medi degli strati di profondità SoilGrids.

Strato	Punto medio (cm)
0–5 cm	2.5
5–15 cm	10.0
15–30 cm	22.5
30–60 cm	45.0
60–100 cm	80.0
100–200 cm	150.0

Questa normalizzazione è fondamentale perché gli strati SoilGrids hanno spessori diversi (5, 10, 15, 30, 40 e 100 cm): senza normalizzazione, il gradiente tra 60–100 cm e 100–200 cm (distanza di 70 cm tra i centri) non sarebbe comparabile con quello tra 0–5 cm e 5–15 cm (distanza di 7.5 cm).

5.4 Selezione delle 15 Feature Finali

Dopo il calcolo, sono state selezionate **15 feature** suddivise in tre gruppi tematici (Tabella 3):

Tabella 3: Le 15 feature selezionate per il clustering, raggruppate per tipologia.

Gruppo	Feature	Interpretazione
Delta Macro	clay_delta_total	Accumulo/depauperamento argilla
	soc_delta_total	Perdita carbonio organico
	phh2o_delta_total	Variazione acidità
	cec_delta_total	Variazione reattività chimica
	bdod_delta_total	Variazione compattazione
Topsoil	soc_grad_0-5_to_5-15	Crollo iniziale sost. organica
	soc_grad_5-15_to_15-30	Esaurimento zona radicale
	clay_grad_5-15_to_15-30	Inizio lisciviazione argilla
	bdod_grad_5-15_to_15-30	Inizio compattazione
	phh2o_grad_5-15_to_15-30	Primi cambiamenti pH
Profondo	clay_grad_15-30_to_30-60	Orizzonte argillico (Bt)
	bdod_grad_15-30_to_30-60	Suola di lavorazione
	cec_grad_15-30_to_30-60	Attività chimica zona accumulo
	clay_grad_30-60_to_60-100	Transizione substrato inerte
	cec_grad_60-100_to_100-200	Cambiamento chimico profondo

5.5 Analisi di Correlazione delle Feature Ingegnerizzate

Le correlazioni tra le feature ingegnerizzate sono state analizzate separatamente per ciascun gruppo tematico. In particolare:

- I **delta macro** confermano la correlazione attesa tra CEC e SOC (la capacità di scambio cationico è legata alla materia organica).
- Le **transizioni superficiali** mostrano correlazione negativa tra il gradiente SOC e il gradiente BDOD (dove la sostanza organica cala, la densità aumenta).
- Le **dinamiche profonde** evidenziano il legame tra accumulo di argilla e aumento della CEC in profondità.




Figura 3: Matrice di correlazione dei delta totali (fondo – superficie) per le 5 variabili principali.




Figura 4: Correlazione dei gradienti normalizzati per zona di profondità.

6 Metodologia

6.1 Standardizzazione dei Dati

Le 15 feature selezionate presentano scale e deviazioni standard molto diverse (ad esempio, il pH varia tra 4 e 9, mentre la CEC può superare 50 cmol_c/kg). Per evitare che le variabili a scala maggiore dominino il calcolo delle distanze euclidee, è stato applicato uno **StandardScaler**:

$$\tilde{x}_j = \frac{x_j - \mu_j}{\sigma_j} \quad (3)$$

dove μ_j e σ_j sono rispettivamente la media e la deviazione standard della j -esima feature sul dataset completo.

6.2 Campionamento per Ottimizzazione

Per rendere computazionalmente fattibile la ricerca degli iperparametri (in particolare il calcolo del Coefficiente di Silhouette, che ha complessità $O(n^2)$), è stato estratto un campione casuale stratificato di **15 000 pixel** dal dataset standardizzato.

6.3 Algoritmo 1: K-Means

L'algoritmo K -Means partiziona n osservazioni in K cluster minimizzando la **Sum of Squared Errors** (SSE) intra-cluster:

$$\text{SSE} = \sum_{k=1}^K \sum_{\mathbf{x}_i \in C_k} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2 \quad (4)$$

dove $\boldsymbol{\mu}_k$ è il centroide del cluster C_k .

6.3.1 Ricerca del K Ottimale

La determinazione del numero ottimale di cluster è stata affrontata con quattro strategie complementari:

1. **Ottimizzazione Bayesiana (Optuna)**: ricerca nello spazio degli iperparametri ($K \in [2, 12]$, $\text{n_init} \in \{10, 20\}$, $\text{max_iter} \in [200, 500]$, $\text{init} \in \{\text{k-means++}, \text{random}\}$) per massimizzare il Coefficiente di Silhouette, con 20 trial.
2. **GridSearchCV**: esplorazione esaustiva con validazione incrociata “leave-all-in” (split unico) su $K \in [2, 12]$.
3. **Metodo del Gomito**: identificazione del punto di flesso nella curva di inerzia mediante calcolo della distanza massima dalla retta che congiunge i punti estremi.
4. **Silhouette Standard**: massimizzazione del Coefficiente di Silhouette al variare di K .

I risultati dei quattro metodi sono stati aggregati con un **sistema di voto a maggioranza**: il K proposto più frequentemente viene adottato; in caso di parità, si sceglie la mediana dei candidati.

```

1 def objective(trial):
2     n_clusters = trial.suggest_int('n_clusters', 2, 12)
3     n_init = trial.suggest_categorical('n_init', [10, 20])
4     max_iter = trial.suggest_int('max_iter', 200, 500, step=100)

```

```

5     init = trial.suggest_categorical('init', ['k-means++', 'random'])
6
7     model = KMeans(n_clusters=n_clusters, n_init=n_init,
8                   max_iter=max_iter, init=init, random_state=42)
9     labels = model.fit_predict(X_search)
10    return silhouette_score(X_search, labels)
11
12 study = optuna.create_study(direction='maximize')
13 study.optimize(objective, n_trials=20)

```

Listing 2: Ricerca iperparametri con Optuna.

6.3.2 Forzatura Agronomica a $K=5$

Sebbene metriche come la Silhouette tendano a favorire valori bassi di K (ad esempio $K = 2$), che producono una separazione binaria del territorio, da un punto di vista agronomico è opportuno cogliere sfumature più fini (ad esempio, distinguere tra argille reattive e inattive, o tra suoli con diverso grado di lisciviazione).

Sulla base del Metodo del Gomito e di considerazioni pedologiche, il modello finale è stato addestrato con $K=5$.

6.4 Algoritmo 2: DBSCAN

Il **DBSCAN** (Density-Based Spatial Clustering of Applications with Noise) identifica cluster come regioni ad alta densità separate da regioni a bassa densità, classificando come *rumore* (-1) i punti isolati.

Due sono i parametri chiave:

- ε (**eps**): raggio massimo del vicinato.
- **min_samples**: numero minimo di punti per formare un nucleo denso.

La determinazione di ε è stata effettuata tramite il **grafico K-NN distance**: calcolando la distanza dal k -esimo vicino più prossimo (con $k = \text{min_samples} = 30$) e ordinando i valori in modo crescente, si individua il punto di ginocchio che segna il passaggio da “densità intra-cluster” a “distanza inter-cluster”. Il valore scelto è stato $\varepsilon = 1.8$.




Figura 5: Grafico delle distanze K-NN per la determinazione dell'epsilon ottimale del DBSCAN.

6.5 Algoritmo 3: Bisecting K-Means

Il **Bisecting K-Means** è un approccio gerarchico *divisivo* (top-down): parte da un unico macro-cluster e lo suddivide iterativamente in due sotto-cluster fino a raggiungere il numero desiderato di partizioni.

A ogni iterazione, il cluster con la varianza interna maggiore viene selezionato e bipartito con un K-Means a $K = 2$. Il processo è stato configurato con $K = 6$ per garantire un confronto equo con il K-Means standard.

6.6 Riduzione Dimensionale: PCA

Per la **visualizzazione** dei cluster nello spazio delle feature (15 dimensioni), è stata applicata un'analisi delle Componenti Principali (PCA) per proiettare i dati in 2D:

$$\mathbf{z}_i = \mathbf{W}^\top \tilde{\mathbf{x}}_i \quad (5)$$

dove $\mathbf{W} \in \mathbb{R}^{15 \times 2}$ è la matrice delle prime due componenti principali, calcolate come gli autovettori associati ai due autovalori maggiori della matrice di covarianza.

6.7 Metriche di Validazione

La validazione dei modelli è stata condotta con due metriche interne (non richiedono etichette ground-truth):

Coefficiente di Silhouette. Per ogni campione i :

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \quad (6)$$

dove $a(i)$ è la distanza media intra-cluster e $b(i)$ è la distanza media al cluster più vicino. Il valore medio $\bar{s} \in [-1, 1]$: valori prossimi a 1 indicano cluster ben separati.

Sum of Squared Error (SSE / Inerzia). Definita nell'Eq. (4), misura la coesione interna dei cluster. Un valore più basso indica cluster più compatti. Questa metrica non è applicabile al DBSCAN.

7 Risultati Sperimentali

7.1 Ricerca del K Ottimale

I risultati della ricerca iperparametri sono sintetizzati nella Tabella 4.

Tabella 4: Riepilogo dei valori di K suggeriti dai quattro metodi.

Metodo	K suggerito
Silhouette Standard	—
Metodo del Gomito	—
GridSearchCV	—
Optuna	—
K finale (voto)	5

Nota: i valori specifici dei singoli metodi vanno compilati con i risultati dell'esecuzione.




Figura 6: Metriche per la selezione del K ottimale.




Figura 7: Analisi dell'ottimizzazione bayesiana con Optuna.

7.2 Visualizzazione Avanzata con Yellowbrick

La libreria Yellowbrick ha fornito tre visualizzazioni diagnostiche:




Figura 8: Diagnostiche Yellowbrick per la validazione del clustering.

7.3 Proiezione PCA dei Cluster

La Figura 9 mostra la proiezione dei cluster nello spazio delle prime due componenti principali.




Figura 9: Proiezione PCA 2D dei cluster K -Means. Le percentuali sugli assi indicano la varianza spiegata da ciascuna componente.

7.4 Mappatura Spaziale dei Cluster

Nonostante l'algoritmo non abbia ricevuto informazioni spaziali (coordinate geografiche), i cluster assumono una distribuzione geografica coerente con la geomorfologia della Capitanata (Figura 10).




Figura 10: Mappatura spaziale dei cluster K -Means con $K=5$ sulla regione Capitanata. La coerenza geografica dei cluster conferma la validità pedologica dell'analisi.




Figura 11: Confronto delle mappature spaziali per DBSCAN e Bisecting K -Means.

7.5 Profilazione dei Cluster

La heatmap dei centroidi standardizzati (Z-score) permette di interpretare il “profilo agronomico” di ciascun cluster (Figura 12).




Figura 12: Profilo agronomico dei cluster basato sugli Z-score dei centroidi. Valori positivi (rossi) indicano gradienti superiori alla media regionale; valori negativi (blu) indicano gradienti inferiori.

7.6 Validazione e Confronto dei Modelli

La Tabella 5 riporta il confronto quantitativo tra i tre algoritmi.

Tabella 5: Confronto delle metriche di validazione interna.

Algoritmo	Silhouette ($\uparrow$)	SSE / Inerzia ($\downarrow$)
K-Means ($K = 5$)	—	—
Bisecting K-Means ($K = 6$)	—	—
DBSCAN ($\varepsilon = 1.8$)	—	N/A

Nota: i valori numerici vanno compilati con i risultati dell'esecuzione.

7.7 Efficienza Computazionale: K-Means vs Mini-Batch K-Means

Per valutare la scalabilità dell’approccio su dataset geospaziali di grandi dimensioni, è stato condotto un confronto tra *K-Means* standard e **Mini-Batch K-Means** (Tabella 6).

Il Mini-Batch *K-Means* elabora i dati a blocchi di dimensione fissa (`batch_size` = 1024), aggiornando i centroidi in modo incrementale. Questo approccio riduce drasticamente il tempo di addestramento con un trade-off minimo in termini di inerzia.

Tabella 6: Confronto efficienza su $\sim 94\,000$ pixel.

Algoritmo	Tempo (s) ($\downarrow$)	Inerzia ($\downarrow$)
K-Means Standard	—	—
Mini-Batch K-Means	—	—

Nota: i valori numerici vanno compilati con i risultati dell’esecuzione.

8 Discussione e Conclusioni

8.1 Sintesi dei Risultati

Il lavoro ha dimostrato che l’approccio basato sui **gradienti verticali** consente di superare i limiti del clustering bidimensionale, catturando informazioni sulla struttura tridimensionale del profilo pedologico. I principali risultati sono:

1. La **feature engineering** basata su delta totali e gradienti normalizzati si è dimostrata efficace nel catturare le dinamiche verticali del suolo, producendo cluster con interpretazione agronomica chiara.
2. Il **K-Means** con $K=5$ ha prodotto la migliore separazione spaziale, con cluster geograficamente coerenti con la geomorfologia della Capitanata.
3. Il **DBSCAN** ha classificato una porzione significativa di pixel come rumore, confermando che la distribuzione dei dati nello spazio dei gradienti non è caratterizzata da cluster a densità nettamente diversa, ma piuttosto da regioni a densità omogenea (scenario favorevole al *K-Means*).
4. Il **Bisecting K-Means** ha fornito risultati comparabili al *K-Means* standard, con una lieve differenza nella gerarchia di suddivisione che potrebbe essere sfruttata per analisi a risoluzione variabile.
5. Il **Mini-Batch K-Means** ha confermato la scalabilità dell’approccio a dataset geospaziali di grandi dimensioni, con un’accelerazione significativa e una perdita di inerzia trascurabile.

8.2 Limiti dello Studio

- **Assenza di ground-truth:** trattandosi di clustering non supervisionato, non è possibile calcolare metriche esterne (Adjusted Rand Index, NMI). La validazione si basa su indici interni e coerenza spaziale.
- **Risoluzione spaziale:** la griglia SoilGrids a 250 m media le proprietà su pixel relativamente grandi, potendo mascherare variabilità locale.
- **Scelta di K :** la forzatura agronomica del K è stata guidata da conoscenze di dominio, ma potrebbe beneficiare di una validazione con dati di campo.

8.3 Sviluppi Futuri

Possibili estensioni del lavoro includono:

- L'integrazione di **dati climatici e morfologici** (precipitazioni, pendenza, uso del suolo) come feature aggiuntive.
- L'applicazione di algoritmi di clustering **spazialmente vincolati** che incorporino la prossimità geografica nel calcolo delle distanze.
- L'estensione dell'analisi all'**intera regione Puglia** o al Sud Italia per validare la generalizzabilità dell'approccio.
- L'impiego di tecniche di **deep clustering** (autoencoders + clustering nello spazio latente) per catturare relazioni non lineari tra le feature.

Riferimenti bibliografici

- [1] Poggio, L., de Sousa, L.M., Batjes, N.H., et al. (2021). *SoilGrids 2.0: producing soil information for the globe with quantified spatial uncertainty*. SOIL, 7, 217–240.
- [2] MacQueen, J. (1967). *Some methods for classification and analysis of multivariate observations*. Proceedings of the 5th Berkeley Symposium on Mathematical Statistics and Probability, 1, 281–297.
- [3] Ester, M., Kriegel, H.-P., Sander, J., & Xu, X. (1996). *A density-based algorithm for discovering clusters in large spatial databases with noise*. Proceedings of KDD-96, 226–231.
- [4] Rousseeuw, P.J. (1987). *Silhouettes: A graphical aid to the interpretation and validation of cluster analysis*. Journal of Computational and Applied Mathematics, 20, 53–65.

- [5] Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). *Optuna: A Next-generation Hyperparameter Optimization Framework*. Proceedings of the 25th ACM SIGKDD, 2623–2631.
- [6] Pedregosa, F., Varoquaux, G., Gramfort, A., et al. (2011). *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, 12, 2825–2830.
- [7] Steinbach, M., Karypis, G., & Kumar, V. (2000). *A comparison of document clustering techniques*. KDD Workshop on Text Mining.